DOI:10.19454/j.cnki.cn15-1170/c.2021.06.005

多元统计方法是否需要对变量进行加权

-以判别分析和聚类分析为例

〇文/李子宁

文章以判别分析和聚类分析为例,在理论上证明了对变量加权是否会对结果产生影响,并进行了实证 分析。研究结果表明,是否对变量加权不影响判别分析结果,但影响聚类分析结果。这一结论可进一 步拓展,即凡是以马氏距离为基础的方法不需要对变量进行加权,而以欧氏距离为基础的方法如果对 变量进行加权可以提高分析结果的准确度。

器学习是一门新兴的交叉学科,它既包括 一些传统的多元统计方法, 如聚类分析、 判别分析、逻辑回归、因子分析等,也包 括一些人工智能方法,如 K 近邻法、决 策树、人工神经网络、支持向量机等。在这些方法中, 也许 K 近邻法是最简单的方法,它的基本思想是以 K 个最近邻居在因变量取值的平均数作为新样品的预测 值。它又派生出基于变量重要性的加权 K 近邻和基于 观测重要性的加权 K 近邻。由于其它统计方法都不涉 及邻居,因此基于观测重要性的加权方法不具有外推性。 那么基于变量重要性的加权方法是否具有外推性呢?或 者说,我们常用的判别分析、聚类分析等需不需要对变 量进行加权呢? 文章将对此问题进行理论和实证分析。

一、基于变量重要性加权的基本原理:以K近邻 法为例

(一)变量重要性的确定方法

变量的重要性可以从三个方面进行考察,一是从 变量本身考察, 二是从解释变量与被预测变量的相关 性角度考察, 三是从预测误差角度考察[1]。

从变量自身来考察,变异程度最大的变量重要性 更强,如果一个变量是常数,没有什么变异,则这个 变量对预测是没有意义的。对数值型变量来说, 衡量 变异性的常用指标是方差、标准差和变异系数,由于 方差和标准差受计量单位的影响, 在衡量变量重要性 时并不适用,通常采用变异系数,即变异系数越大的 变量越重要。对于类别变量,如果各个类别值的取值 比例相当,则这个变量越重要;如果某个类别的取值 比例越大,则这个变量越不重要。以二分类变量为例, 如果两个类别的取值比例均为 0.5, 此时这个类别变量 的方差取最大值 0.25; 而如果一个类别所占比例为 0.9, 另一个类别所占比例为 0.1, 此时这个类别变量的方差 仅为 0.09。

从解释变量与被预测变量的相关性角度来考察, 又可以分成三种情况。第一种情况是解释变量与被预 测变量均为类别变量。衡量类别变量间相关与否的统 计量为卡方统计量,卡方统计量越大,类别变量间的 相关程度就越大,因此卡方越大的变量或 p 值越小的 变量越重要。第二种情况是解释变量与被解释变量均 为连续变量。连续变量相关与否的统计量为相关系数, 相关系数越大,变量间的相关性越强; 当然前提是相 关系数必须是显著的,这可以通过 t 统计量进行检验。 第三种情况是解释变量和被预测变量分属不同类别, 具体包括两类:解释变量是类别变量,被预测变量是 连续变量;解释变量是连续变量,被预测变量是类别 变量。无论是两种情况中的哪一种,均采用方差分析 的方法, 即计算 F 统计量, F 统计量越大, 表明变量 之间相关性越强。

从预测误差角度来考察,通常与建模策略有关。 建模策略有两种,一是"从一般到具体"建模策略, 二是 "从具体到一般"建模策略。若采用"从一般到 具体"建模策略,首先将全部变量加入模型,然后分 别去掉一个解释变量,建立 K 个 K-1 元模型,在这 K 个 K-1 元模型中, 哪个模型的预测误差最大, 说明该 模型所不包含的那个变量重要性越大。若采用"从具 体到一般"建模策略,则可直接比较 K 个一元模型,哪个模型的拟合程度越好(即误差越小),即说明哪个变量的重要性越大。一般认为,"从一般到具体"建模策略更好,因为"从具体到一般"建模策略可能会造成遗漏变量问题。

(二)变量权重的确定方法

根据变量重要性的确定方法,令第 i 个解释变量的权重为w,它是解释变量重要性的函数,可定义为:

$$w_i = \frac{FI_i}{\sum FI_i}$$

其中 FI_i 为解释变量重要性,从机器学习角度又被称为特征重要性,它以输入变量对预测误差的影响定义。假定有 K 个输入变量, x_1 , x_2 , …, x_k , 剔除第 i 个变量,计算输入变量为 x_1 , x_2 , …, x_{i-1} , x_{i+1} , …, x_k 下,K 近邻法的错判概率,记作 e_i 。若第 i 个变量对预测有重要作用,剔除该变量后的预测误差将比较大。因此第 i 个变量的重要性定义为: $FI_i = e_i + \frac{1}{k}$ 。因此不论从哪个角度来考察,变量越重要,在计算距离时其权重越大。

由于 K 近邻法采用欧氏距离测度近邻观测,则加权的欧氏距离为:

EUCLID(x,y)=
$$\sqrt{\sum w_i(x_i-y_i)^2}$$

(三)使用 K 近邻法进行预测

对于二分类预测问题,如果有超过半数的近邻类别值为1,则预测值为1类,否则预测值为0类。对于多分类预测问题,预测值为众数。对于回归预测问题,预测值是K个近邻在被预测变量上的平均值。

二、判别分析是否需要对变量进行加权

判别分析是指在已知研究对象分成若干组的情况下,判断新的样品应归属的组别。在判别分析中,最直观的判别方法就是距离判别,即计算新样品到各组的距离,新样品距离哪组最近,就被判为哪一组。

(一)两组距离判别

设组 π_1 和 π_2 的均值分别为 μ_1 和 μ_2 ,协方差 矩阵分别为 Σ_1 和 Σ_2 ,x 是一个新样品,现判断它来 自哪一组。

若不对变量进行加权,计算 x 到两个组的距离 $d^2(x, \pi_1)$ 和 $d^2(x, \pi_2)$,并按如下的判别规则进行判断 [1]:

$$\begin{cases} x \in \pi_1 & \text{ if } d^2(x, \pi_1) \leq d^2(x, \pi_2) \\ x \in \pi_2 & \text{ if } d^2(x, \pi_1) > d(x, \pi_2) \end{cases}$$
 (1)

1. Σ_1 = Σ_2 = Σ 时的判别。若对变量进行加权,设 w_i 为第 i 个判别变量的权重,则加权后的判别向量为 x^* =wx,均值向量为 $w\mu$,方差协方差矩阵为 $w\Sigma w'$ 。

经过加权的平方马氏距离为:

 $d^{2}(x^{*}, \pi_{1}) = [w(x-\mu_{1})]'(w \sum w')^{-1}[w(x-\mu_{1})]$ $d^{2}(x^{*}, \pi_{2}) = [w(x-\mu_{2})]'(w \sum w')^{-1}[w(x-\mu_{2})]$ 其中 w 为对角矩阵:

$$\mathbf{W} = \left[\begin{array}{ccc} \mathbf{W}_1 \\ & \mathbf{W}_2 \\ & & \cdots \\ & & \mathbf{W}_p \end{array} \right]$$

判别规则为:

$$x \in \pi_1$$
 若 $d^2(x^*, \pi_1) \le d^2(x^*, \pi_2)$
 $x \in \pi_2$ 若 $d^2(x^*, \pi_1) > d(x^*, \pi_2)$

将加权的平方马氏距离展开:

$$\begin{split} d^2(x^*,\, \boldsymbol{\pi}_{_1}) &= (x \! - \! \boldsymbol{\mu}_{_1})' \, w' \, (w')^{-1} \, \boldsymbol{\Sigma}^{\! -1} w^{\! -1} \, w (x \! - \! \boldsymbol{\mu}_{_1}) \\ &= (x \! - \! \boldsymbol{\mu}_{_1})' \boldsymbol{\Sigma}^{\! -1} (x \! - \! \boldsymbol{\mu}_{_1}) \\ &= \! d(x\,,\, \boldsymbol{\pi}_{_1}) \\ d^2(x^*,\, \boldsymbol{\pi}_{_2}) &= (x \! - \! \boldsymbol{\mu}_{_2})' \, w' \, (w')^{-1} \, \boldsymbol{\Sigma}^{\! -1} w^{\! -1} \, w (x \! - \! \boldsymbol{\mu}_{_2}) \\ &= (x \! - \! \boldsymbol{\mu}_{_2})' \boldsymbol{\Sigma}^{\! -1} (x \! - \! \boldsymbol{\mu}_{_2}) \\ &= \! d(x\,,\, \boldsymbol{\pi}_{_2}) \end{split}$$

由于 $d(x^*, \pi_1) = d(x, \pi_1)$, $d(x^*, \pi_2) = d(x, \pi_2)$ 。 所以在两组距离判别且假定方差阵相等时,对变量加权并不影响判别分析的结果。

2. $\Sigma_1 \neq \Sigma_2$ 时的判别。若对变量进行加权,则 $d^2(x^*, \pi_1)$ 和 $d^2(x^*, \pi_2)$ 的计算公式为:

因此在两组距离判别且方差阵不相等时,对变量 加权也不影响判别分析的结果。

(二)多组距离判别

 $=d(x, \pi_2)$

设有 k 个组 π_1 , π_2 , …, π_k , 它们的均值分别为 $\mu_1\mu_2$, …, μ_k , 协方差矩阵分别是 Σ_1 , Σ_2 , …, Σ_k , x 到总体 π_1 的加权平方马氏距离为:

 $d^2(x^*, \pi_i) = [w(x-\mu_i)]'(w\sum_i w')^{-1}[w(x-\mu_i)]$ 判别规则为:

$$x \in \pi_i$$
, $\stackrel{\text{def}}{=} d^2(x^*, \pi_1) = \min_{\substack{1 \leq i \leq k \\ 1 \leq j \leq k}} d^2(x^*, \pi_1)$

由于 $d^2(x^*, \pi_i) = d^2(x, \pi_i)$,所以在多组距离判别下,对变量加权与否不影响判别结果。

三、聚类分析是否需要对变量进行加权

聚类分析是一种无监督学习方法,没有目标变量, 因此聚类分析中一般不采用马氏距离, 而采用欧氏距 离。但欧氏距离与各变量的量纲有关,没有考虑变量 间的相关性,也没有考虑各变量方差的不同[3]。因此 对变量是否加权会影响聚类结果。

当不对变量进行加权时,两个样品之间的平方欧 氏距离为:

$$d^{2}(x,y) = (x-y)'(x-y)$$

当对变量进行加权时,两个样品之间的平方欧氏 距离为:

$$d^{2}(x^{*}, y^{*}) = [w(x-y)]'[w(x-y)]$$

通常 $d^2(x,y) \neq d(x^*,y^*)$, 因此两种情况下的聚类 结果一般不会相同。

若对数据进行标准化,令 $x^{s}=\sum^{\frac{1}{2}}(x-\mu)$, $y^{s}=\sum^{\frac{1}{2}}$ $(y-\mu)$, 显然有 $E(x^s) = E(y^s) = 0$, $V(x^s) = V(y^s) = I$,

$$\begin{split} d^{2}(x^{s},y^{s}) &= [\ \sum^{\frac{1}{2}}(x-\mu) - \sum^{\frac{1}{2}}(y-\mu) \]'[\ \sum^{\frac{1}{2}}(x-\mu) - \sum^{\frac{1}{2}}(y-\mu) \] \\ &= (x-y)' \sum^{\frac{1}{2}} \sum^{\frac{1}{2}}(x-y) \\ &= (x-y)' \sum^{-1}(x-y) = d^{2}(x,y) \end{split}$$

因此,变量标准化之后的平方欧氏距离等价于标 准化前的平方马氏距离。所以在进行聚类分析时,如 果选择对变量进行标准化,是否对变量进行加权对聚 类分析结果没有影响。

四、实证分析

(一)对加权和不加权情况下判别分析的验证

文章以费希尔判别分析的经典例子来验证对变量 加权与否的影响。费希尔于 1936 年发表的鸢尾花数据 包括3种鸢尾花: 刚毛鸢尾花、变色鸢尾花和弗吉尼 亚鸢尾花,每种各抽取一个容量为50的样本,测量了 花萼长、花萼宽、花瓣长、花瓣宽4个变量。

无论采用何种判别方法,都可能会产生误判。误 判比例的计算通常有四种方法,一是直接用样本计算 判别函数,同时计算误判比例,这种方法给出的误判 比例通常较低;二是旁置法,即拿出样本的一部分(通 常为70%)作为训练样本集构造判别函数,剩余的部 分作为测试样本集计算误判比例; 三是十折交叉验证 法, 即将样本分成十部分, 每次取其中的九部分作为 训练样本集构造判别函数,剩余的一部分作为测试样 本集计算误判比例,十折交叉验证要构造十个判别函 数;四是刀切法,即每次拿出一个观测作为测试样本, 其余的观测作为训练样本集构造判别函数。刀切法避 免了样本数据在构造判别函数的同时又被用来对该判 别函数进行评价, 也几乎避免了构造判别函数时样本 信息的损失。

文章采用第一种和第四种计算误判比例的方法。 其中表 1 为未对变量进行加权的距离判别结果,表 2 为按预测误差加权的距离判别结果。



表 1 未对变量加权的距离判别结果

组别		预测类别					
4日カリ			1	2	3	Total	
原始类别	频数	1	50	0	0	50	
		2	0	48	2	50	
		3	0	1	49	50	
刀切法验证	频数	1	50	0	0	50	
		2	0	48	2	50	
		3	0	1	49	50	

表 2 对变量加权的距离判别结果

组别						
===700			1	2	3	Total
原始类别		1	50	0	0	50
	频数	2	0	48	2	50
		3	0	1	49	50
刀切法验证	频数	1	50	0	0	50
		2	0	48	2	50
		3	0	1	49	50

表 1 和表 2 中, 无论直接采用判别函数验证, 还 是采用刀切法验证,是否对变量进行加权的结果完全 相同。

(二)对加权和不加权情况下聚类分析的验证

我们仍然使用费希尔的数据,其中编号 1-50 属 刚毛鸢尾花,编号51-100属变色鸢尾花,编号101-150 属弗吉尼亚鸢尾花。聚类变量为花萼长、花萼宽、 花瓣长、花瓣宽4个变量,聚类方法采用组间连接法, 聚类数目为3类。当未对变量进行加权时,编号1-50 仍被分到第一组、编号51-100仍被分到第2组、但 编号 100-150 中只有 110、112、118、120、122、 127、130、131、135、138、140、144被分到第三组, 其余38个被错分到了第二组。当对变量进行加权时, 前 50 个观测仍被分到第一组,编号 51-99 被分到第二 组,但编号100被分到了第三组;编号101-150中只 有 14 个被错误分到了第二组。因此对变量进行加权的 聚类分析, 其聚类效果好于不对变量进行加权的聚类分 析。另外,在变量加权和不加权两种情况下,如果在聚 类分析时选择对变量进行标准化,则结果完全相同。

五、结论与拓展

从理论和实证分析来看,凡是采用马氏距离的方 法,都不需要对变量进行加权。凡是采用欧氏距离的 方法,如果不对变量进行标准化,则是否加权影响分 析结果; 若对变量进行标准化, 欧氏距离等同于马氏 距离,是否加权对分析结果没影响。

这一结论可以进一步拓展。比如典型判别, 其实 质是二阶段判别,第一阶段降维,第二阶段采用降维 后的主成分进行距离判别。因此典型判别本质上仍是 距离判别,由于距离判别采用马氏距离,是否对变量 进行加权并不影响典型判别的结果。对于 K 近邻法, 如果采用马氏距离,则不需要对变量进行加权,也就 没有所谓的基于变量加权的 K 近邻法; 但目前统计软 件都是基于欧氏距离或街区距离, 且默认对变量进行 标准化,此时对变量是否加权不影响结果;如果不对 变量进行标准化,则基于变量加权的 K 近邻法和普通 的 K 近邻法在分析结果上是有差异的。

对于因子分析和主成分分析, 其基本原理是对方 差矩阵或相关矩阵进行分解。统计软件一般默认基于 相关矩阵进行分析[4],此时是否对变量进行加权不影 响结果;但若基于协方差矩阵进行分析,是否对变量 加权会影响分析结果。

基金项目:河北省高等教育教学改革与研究项目"经济统计专业推 进课程思政的探索与实践(批准号: 2020GJJG590)"阶段性成果。

作者单位:河北工业大学理学院

参考文献

- [1] 薛薇 .R 语言数据挖掘方法及应用 [M]. 电子工业出版社 ,2016.
- [2] 王学民,应用多元分析(第五版)[M],上海财经大学出版社,2017.
- [3] 高惠璇. 应用多元统计分析 [M]. 北京大学出版社,2005.
- [4] 李国柱 .SPSS 统计分析基础 [M]. 国家开放大学出版社 ,2018.